

失败案例分析

失败案例从 [experiments/failure_analysis.py](#) 自动捞取（LoRA_50 跑全 test 600 张 + 几何法抽样 200 张分量估计），再人工归因、归类、给改进方向。

数据来源：[results/failure_cases_raw.json](#)。整体统计：

- 识别错误：111/600 = 18.5%（LoRA_50 模式，Top-1 81.5%）
- 分量误差（>60g，2× 硬指标）：抽样 200 张中 8 张
- 低置信（conf<0.3）失败：1 张

失败案例比成功案例更有信息量，它揭示模型的边界：哪些类易混、哪种拍摄条件下识别/分量会崩。本文按"识别混淆""分量误差""低置信门控""跨场景""分割失败"五类归因，共 18 例。

1 识别混淆案例（细粒度相似类，共 10 例）

中餐的细粒度相似类是本数据集识别的主要错误源。这 10 例覆盖了混淆频次最高的 8 个混淆对，归因高度一致：类间视觉特征高度重叠（颜色/形态/容器雷同），CLIP 文本侧无法仅凭菜名语义区分。

1.1 案例 1：包子误判为小笼包（混淆 6 次，最高频）

- 样本：[dataset_50cls/test/15_包子/15_004392.jpg](#)
- 模型输出：pred=小笼包 conf=0.907；top3=[小笼包 0.907, 包子 0.09, 肉夹馍 0.001]
- 归因：包子与小笼包同属"面皮包肉馅"的蒸制面点，形态（圆白面皮+褶皱）、颜色、容器（蒸笼）几乎一致，唯一差异是尺寸（包子大、小笼包小），但 CLIP 图像编码器对绝对尺寸不敏感，且菜名"包子/小笼包"的语义都指向"蒸制面点"，文本侧无法区分尺寸。这是典型的"类间特征重叠 > 类名语义区分力"。
- 改进方向：① 在文本模板里加尺寸提示（如"大个的{c}"vs"小个的{c}"）；② 引入餐盘/筷子等参照物做尺寸标定（参考物法）；③ 训练时对此类易混对做 hard negative mining。

1.2 案例 2：炒面误判为凉面（混淆 5 次）

- 样本：[dataset_50cls/test/41_炒面/41_000498.jpg](#)
- 模型输出：pred=凉面 conf=0.958；top3=[凉面 0.958, 酸辣土豆丝 0.02, 炒面 0.013]
- 归因：炒面与凉面都是"面条+蔬菜/酱料"的形态，颜色相近（酱油色面条），差异在温度/油光（炒面油亮、凉面偏干），但 CLIP 的图像编码器对"油光/温度"这类细微视觉线索捕捉弱。高 conf 0.958 说明模型"自信地错"，这是最危险的失败模式。
- 改进方向：① 训练时对炒面/凉面做数据增强（调整对比度突出油光）；② 文本模板加烹饪方式提示（"热炒的{c}"vs"凉拌的{c}"）。

1.3 案例 3：冰淇淋误判为双皮奶（混淆 5 次）

- 样本：[dataset_50cls/test/49_冰淇淋/49_007933.jpg](#)
- 模型输出：pred=双皮奶 conf=0.992；top3=[双皮奶 0.992, 冰淇淋 0.006, 蒸蛋羹 0.002]
- 归因：冰淇淋与双皮奶都是"白色/浅色、奶油状质地、盛在碗里"的甜品，视觉特征高度重叠（白色团状物+碗）。0.992 的极高 conf 说明 CLIP 把这张冰淇淋图的特征完全匹配到了双皮奶，可能是该冰淇淋图为非典型形态（如装碗的软冰淇淋，非甜筒）。这是"类内非典型样本 + 类间相似"的双重失败。
- 改进方向：① 数据清洗，剔除非典型样本；② 训练时对易混甜品类做 oversample。

1.4 案例 4：饺子误判为煎饺（混淆 4 次）

- 样本: [dataset_50cls/test/14_饺子/14_014934.jpg](#)
- 模型输出: pred=煎饺 conf=0.578; top3=[煎饺 0.578, 饺子 0.407, 小笼包 0.011]
- 归因: 饺子与煎饺是同一食物的不同烹饪态（水煮 vs 油煎），形态（半月形面皮+馅）、颜色（煎饺底部金黄）相近。conf 0.578 是"低置信错误"，模型在两者间摇摆，说明它意识到了不确定性但选错。这类样本适合走"置信度门控"反问（见创新点1）。
- 改进方向: ① 置信度门控阈值下调时触发反问；② 训练时强调"煎饺底部金黄"这一判别特征（文本模板加"底部金黄的{c}"）。

1.5 案例 5：酸菜鱼误判为水煮鱼（混淆 4 次）

- 样本: [dataset_50cls/test/32_酸菜鱼/32_019565.jpg](#)
- 模型输出: pred=水煮鱼 conf=0.930; top3=[水煮鱼 0.93, 酸菜鱼 0.056, 糖醋鱼 0.009]
- 归因: 酸菜鱼与水煮鱼都是"鱼片+红油/酸菜汤底+辣椒"的汤菜，视觉特征（红汤+白鱼片+辣椒碎）高度重叠，差异在酸菜（酸菜鱼有黄色酸菜丝）vs 豆芽/莴笋（水煮鱼垫底）。CLIP 对这种"汤里配料"的细粒度差异捕捉弱。0.93 高 conf 同样是"自信地错"。
- 改进方向: ① 文本模板强调配菜（"带酸菜丝的{c}"）；② 局部裁剪放大配料区域再识别。

1.6 案例 6：米饭误判为扬州炒饭（混淆 4 次）

- 样本: [dataset_50cls/test/44_米饭/44_017035.jpg](#)
- 模型输出: pred=扬州炒饭 conf=0.999; top3=[扬州炒饭 0.999, 米饭 0.001, 酸辣土豆丝 0.0]
- 归因: 米饭与扬州炒饭都是"白色/黄色米粒"，差异在炒饭有蛋碎/葱花/虾仁等配料。0.999 极高 conf 说明该米饭图可能混入了配料（如葱花饭），被误判为炒饭。这是"类内样本不纯"导致的失败，米饭类里有部分带配料的样本。
- 改进方向: ① 数据清洗，把"带配料的白米饭"归入炒饭类或剔除；② 训练时对米饭类做严格筛选。

1.7 案例 7：鱼香茄子误判为地三鲜（混淆 3 次）

- 样本: [dataset_50cls/test/05_鱼香茄子/05_000913.jpg](#)
- 模型输出: pred=地三鲜 conf=0.978; top3=[地三鲜 0.978, 回锅肉 0.011, 鱼香茄子 0.007]
- 归因: 鱼香茄子与地三鲜都是"茄子+酱色炒菜"，差异在鱼香茄子有肉末/泡椒红油、地三鲜有土豆/青椒。但本图可能茄子占比高、肉末少，视觉上接近地三鲜。CLIP 对"主料相同、辅料不同"的菜品区分力弱。
- 改进方向: ① 文本模板强调辅料（"带肉末红油的{c}"vs"带土豆青椒的{c}"）；② 多视角/局部特征增强。

1.8 案例 8：红烧肉误判为红烧牛肉（混淆 3 次）

- 样本: [dataset_50cls/test/10_红烧肉/10_015869.jpg](#)
- 模型输出: pred=红烧牛肉 conf=0.851; top3=[红烧牛肉 0.851, 爆炒腰花 0.095, 红烧肉 0.026]
- 归因: 红烧肉与红烧牛肉都是"酱红色块状肉+浓汤"，差异在肉的纹理（五花肉层 vs 牛肉纤维）。CLIP 对肉的纹理细节捕捉弱，且菜名"红烧肉/红烧牛肉"只差一字，文本语义高度重叠。
- 改进方向: ① 文本模板细化（"五花肉块的{c}"vs"牛肉块的{c}"）；② 高分辨率裁剪肉块区域识别纹理。

1.9 案例 9：煎饺误判为小笼包（混淆 3 次）

- 样本: [dataset_50cls/test/42_煎饺/42_016285.jpg](#)
- 模型输出: pred=小笼包 conf=0.707; top3=[小笼包 0.707, 煎饺 0.27, 包子 0.018]
- 归因: 煎饺与小笼包都是"面皮包馅、蒸制/煎制"，形态（半月形/圆球形）、颜色相近。与案例1、4 同属"面点家族"的细粒度混淆，这是本数据集面点类（包子/小笼包/饺子/煎饺/肉夹馍）的系统性弱点。
- 改进方向: ① 面点类单独训练一个细粒度子分类器；② 引入"烹饪方式"作为辅助特征。

1.10 案例 10：糖醋排骨误判为爆炒腰花/可乐鸡翅/梅菜扣肉（混淆 2+2+2=6 次，最易错类）

- 样本：dataset_50cls/test/11_糖醋排骨/11_008988.jpg（误判为爆炒腰花）、11_013250.jpg（误判为可乐鸡翅）、11_004551.jpg（误判为梅菜扣肉）
 - 模型输出：pred 分别=爆炒腰花(0.908)/可乐鸡翅(0.993)/梅菜扣肉(0.432)
 - 归因：糖醋排骨是本数据集错得最多的类（10 次错），且错向 3 个不同类，说明糖醋排骨类内方差极大（不同做法/摆盘差异大），没有稳定的类原型。糖醋排骨的"排骨+酱色+可能带骨"特征与爆炒腰花（酱色块状）、可乐鸡翅（酱色带骨）、梅菜扣肉（酱色肉）都部分重叠。
 - 改进方向：① 数据清洗，统一糖醋排骨的视觉风格；② 训练时对该类 oversample 或用 hard negative；③ 文本模板加"挂糖醋汁的排骨块"。
-

2 分量估计大误差案例（>60g，共 5 例）

分量估计的失败主要源于分割失败（area_ratio 失准）或类先验锚与真值偏差大。抽样 200 张中 8 张 >60g，取典型 5 例。

2.1 案例 11：饺子 est=318g true=225.6g err=92.4g（最大误差）

- 样本：area_ratio=0.496, modulator=1.3（触顶）
- 归因：area_ratio=0.496 远高于饺子桶中位数（staple 桶 0.267），modulator 被钳到上限 1.3，导致重量被放大到 318g。但真值仅 225.6g，说明该图的食物占图比例确实大（可能近景拍摄），但"大占图≠大分量"，这是面积比法的固有限制：近景拍摄的同一份食物，面积比会虚高。
- 改进方向：① 引入拍摄距离估计（如检测餐盘完整度，盘子完整=远景，盘子出框=近景）；② 对 modulator 上限更保守（如 1.2）。

2.2 案例 12：酸辣粉 est=288g true=367.8g err=79.8g（低估）

- 样本：area_ratio=0.190, modulator=0.8（触底）
- 归因：area_ratio=0.190 低于酸辣粉桶中位数，modulator 被钳到底 0.8，导致低估。但真值 367.8g 偏高，这是"真值偏大 + 估计偏小"的双重偏差。酸辣粉装在深碗里，俯拍时食物可见面积小（碗壁遮挡），area_ratio 系统性偏低。
- 改进方向：① 对碗装食物（汤面/酸辣粉）单独标定；② 多角度拍摄或侧视补偿。

2.3 案例 13：双皮奶 est=318g true=243.0g err=75.0g（高估）

- 样本：area_ratio=0.392, modulator=1.3（触顶）
- 归因：与案例11类似，近景拍摄导致 area_ratio 虚高，modulator 触顶。双皮奶盛在浅碗里，近景时占比大。
- 改进方向：同案例11，引入拍摄距离估计。

2.4 案例 14：薯条 est=147g true=77.2g err=69.8g（高估）

- 样本：area_ratio=0.265, modulator=0.899（近1.0）
- 归因：modulator 接近1.0（面积比与桶中位数接近），误差主要来自类先验锚偏高。薯条的类先验 $\mu=150g$ （snack 桶），但真值仅 77.2g，合成真值按类先验高斯采样，理论上应围绕 μ ，但该样本被采样到偏低值（ $\mu-2\sigma$ 左右）。这是合成真值的固有方差，非估计器错误。
- 改进方向：① 减小合成真值的 σ （但会降低真值多样性）；② 此类误差本质是评估口径限制，报告中如实声明（见 §0.4）。

2.5 案例 15：地三鲜 $\text{est}=211.2\text{g}$ $\text{true}=272.5\text{g}$ $\text{err}=61.3\text{g}$ （分割失败）

- 样本：area_ratio=0.062（极低），modulator=0.8（触底）
 - 归因：area_ratio=0.062 远低于正常水平，说明分割失败，GrabCut 没能把地三鲜从背景里抠出来（可能该图背景杂乱、食物颜色与桌布接近）。分割失败导致面积比虚低，modulator 触底，但先验锚兜底使重量没崩到离谱（211g vs 真 272g）。这验证了 v2 "先验锚兜底"设计的价值：分割失败时退化为先验，不会崩盘。
 - 改进方向：① 改进分割（用 SAM 替代 GrabCut，或更强的显著性先验）；② 检测 area_ratio<0.1 时标记"分割不确定"并降权。
-

3 低置信门控案例（1 例）

3.1 案例 16：红烧肉误判为爆炒腰花（conf=0.263，触发门控）

- 样本：[dataset_50cls/test/10_红烧肉/10_000697.jpg](#)
 - 模型输出：pred=爆炒腰花 conf=0.263；top3=[爆炒腰花 0.263, 宫保鸡丁 0.234, 京酱肉丝 0.168]
 - 归因：conf=0.263 低于门控阈值 $\max(0.3, 81.5\% \times 0.5)=0.407$ ，触发反问。top3 概率分散（0.263/0.234/0.168），说明模型完全不确定。这张红烧肉图可能非典型（如酱色浅、肉块小），与多个酱色肉类都部分相似。
 - 改进方向：① 门控设计正确（已触发反问），但反问时若用户也无法确认，应给出"最像的前三种+建议人工确认"；② 训练时补充红烧肉的非典型样本。
 - 验证：此案例证明创新点1（置信度门控）生效，低置信样本被正确拦截，没有硬猜成爆炒腰花、把错误带进后面的计算。
-

4 跨场景失败案例（2 例）

4.1 案例 17：挑战场景下的识别失败（challenge 子集）

- 背景：scene_eval.json（人工三场景口径）显示 challenge 子集 Top-1=74.51%，低于 standard 78.38%/real 79.58%，是三个场景里最难的（Top-5 仍达 98.04%，说明只是"拿不准具体菜"而非"完全认错"）。但挑战场景里仍有失败，典型为低光照+模糊叠加。
- 归因：低光照导致颜色失真（酱色菜变黑），模糊导致纹理丢失。CLIP 对颜色依赖较强，低光照下失真大。
- 改进方向：① 训练时加低光照/模糊数据增强；② 推理时做图像增强（直方图均衡、去模糊）。

4.2 案例 18：近景拍摄导致分量虚高（跨场景）

- 样本：案例11/13 的共性
 - 归因：近景拍摄（盘子出框）使 area_ratio 系统性虚高，是分量估计在"非标准拍摄"场景下的主要失败模式。scene_eval 中 challenge 子集 MAE=27.2g，仅略高于 standard 24.0g/real 25.1g，说明近景问题被先验锚部分缓解，但个案（案例11/13）仍会出错。
 - 改进方向：① 检测盘子完整度（盘子出框即近景，对 modulator 降权）；② 引入深度估计或拍摄距离提示。
-

5 失败模式总结与系统性改进

失败类型	案例	根因	已有缓解	改进方向
细粒度混淆	1-10	类间视觉重叠>语义区分	文本模板	尺寸/辅料/烹饪提示、hard negative
分量虚高	11,13	近景 area_ratio 虚高	先验锚+modulator 钳制	拍摄距离估计、盘子完整度检测
分量低估	12,15	碗装/分割失败 area_ratio 虚低	先验锚兜底	碗装单独标定、SAM 分割
合成真值方差	14	真值采样偏离 μ	无	如实声明评估口径限制
低置信错误	16	类内非典型样本	门控反问（已生效）	补非典型样本、反问时给 top3
跨场景	17,18	低光照/近景	数据增强（弱）	强增强、图像预处理、距离估计

关键发现：

- 1. 面点家族（包子/小笼包/饺子/煎饺）是系统性弱区，4 类互相混淆，占混淆对的 1/3。根因是面点类视觉特征高度重叠，需单独的细粒度子分类器。
- 2. "自信地错"（conf>0.9 的错误）占混淆案例的 60%，说明 CLIP 的置信度校准有问题，高 conf 不等于高准确。门控阈值不能只看绝对值，应结合 top1-top2 的 margin。
- 3. 分量估计的失败 80% 源于 area_ratio 失准（近景虚高/碗装虚低/分割失败），先验锚兜底避免了崩盘，但个案仍会偏 60-90g。改进重点在分割质量与拍摄距离估计，而非调制公式本身。
- 4. 创新点1（置信度门控）在案例16 验证生效，低置信样本被正确拦截。

教训：失败案例的归因比成功率更能指导改进。本作业的失败集中在"细粒度相似类"和"非标准拍摄（近景/碗装）"两类，前者需更强的文本/局部特征，后者需拍摄距离估计与更强的分割，这两个方向是后续优化的最高优先级。